

Training Dynamics — ViT · Muon · $\eta=0.003$ · b=128

